Compte rendu du projet Unix - Sujet 2 : Constitution d'un dataset multimédia

Membres du groupe

DJOZE Sephanie Morelle

FAYA Lidao Majoie

GUIAGAING MOKAK Dimitri Higor

LEKANE TCHATCHOUANG Sandra

Sous la supervision de :

Mr. HAMROUN

COMPTE RENDU DU PROJET 2 : CONSTITUTION D'UN DATASET MULTIMÉDIA

Introduction

Dans le cadre du projet 2, intitulé « Constitution d'un dataset multimédia », nous avons été amenés à concevoir un programme permettant de collecter, télécharger, organiser et répartir automatiquement des fichiers multimédias à partir de pages web. L'objectif principal était de mettre en place un système automatisé capable de récupérer différents types de médias tout en garantissant leur validité, leur organisation et leur exploitation. Pour réaliser ce travail, nous avons principalement utilisé le langage Shell (Bash), ainsi que plusieurs commandes et outils Linux permettant de manipuler les fichiers, traiter les données et automatiser les différentes opérations.

1. Préparation de l'environnement de travail

La première étape a consisté à préparer l'environnement nécessaire à la réalisation du projet. Nous avons créé une arborescence organisée comprenant les pages HTML, les dossiers destinés au stockage des médias et les différents répertoires de travail. Nous avons également ajouté plusieurs fichiers multimédias ainsi que des fichiers destinés à tester la fiabilité du programme : des copies de fichiers, de faux fichiers images, des documents PDF et des médias inexistants.Un serveur HTTP local a ensuite été lancé afin de rendre les pages HTML accessibles à travers l'adresse locale 127.0.0.1. Cette préparation a permis de disposer d'un environnement de test adapté aux différentes fonctionnalités du programme.

2. Création du script et gestion des configurations

La deuxième étape a porté sur la création du script principal nommé media_dataset_builder.sh. Ce script constitue le cœur du projet puisqu'il permet d'automatiser l'ensemble des opérations de constitution du dataset. Nous avons commencé par définir sa structure, préparer les répertoires nécessaires et le rendre exécutable. Nous avons également mis en place un système de gestion des options permettant notamment d'afficher l'aide et de contrôler les différentes actions du programme. Ensuite, deux fichiers de configuration ont été créés : urls.conf et settings.conf. Le premier contient les adresses des pages à analyser, tandis que le second regroupe les paramètres nécessaires au fonctionnement du script.

Le chargement de ces paramètres est effectué à l'aide de la commande source. Une vérification a également été intégrée afin de s'assurer que les trois proportions de répartition du dataset (train, validation et test) totalisent bien 100 %.

3. Téléchargement et extraction des liens multimédias

La troisième étape consistait à récupérer les pages HTML à partir des URL enregistrées dans le fichier de configuration. Le programme parcourt les différentes adresses en ignorant les lignes vides et les commentaires. Chaque page téléchargée est ensuite enregistrée dans le dossier raw_html avec un nom numéroté. Des mécanismes de contrôle ont été prévus pour vérifier le bon déroulement des téléchargements, respecter un délai entre les requêtes et supprimer les fichiers incomplets en cas d'échec. Une fois les pages récupérées, nous avons développé une fonctionnalité permettant d'en extraire les liens multimédias. Le script recherche les URL correspondant aux extensions de fichiers prévues dans le sujet. Les liens obtenus sont ensuite triés à l'aide de la commande sort -u, ce qui permet de supprimer les doublons. Le résultat est enregistré dans le fichier index/media_links.txt.

4. Téléchargement, vérification et classement des médias

Cette étape représente une partie importante du projet. Elle consiste à télécharger les médias identifiés et à les classer automatiquement selon leur type. Le programme utilise notamment le paramètre MAX_FILES pour limiter le nombre de fichiers téléchargés. Chaque téléchargement fait l'objet de vérifications afin de s'assurer que le fichier est valide et correspond réellement au type de média attendu. Cette vérification permet notamment de rejeter les faux fichiers images et les ressources qui ne respectent pas les critères définis. Nous avons également utilisé les empreintes numériques SHA-256 pour identifier les fichiers identiques. Cette méthode permet de détecter les doublons, même lorsque les fichiers possèdent des noms différents. Les informations relatives aux médias téléchargés, notamment leurs chemins et leurs URL sources, sont conservées afin de faciliter leur suivi et leur exploitation.

5. Création de l'index et répartition du dataset

Après la collecte des médias, nous avons procédé à la création d'un index CSV nommé media_index.csv. Ce fichier permet de centraliser les informations concernant chaque média, notamment son nom, son chemin d'accès, son type, son extension et sa taille. Il constitue une référence pour retrouver et identifier facilement les fichiers collectés. Nous avons ensuite réalisé la répartition du dataset en trois ensembles distincts : **train, validation et test**. Cette opération consiste à mélanger les fichiers, à calculer les effectifs nécessaires en fonction des proportions définies dans le fichier de configuration, puis à copier chaque média

dans un seul des trois ensembles. Cette organisation permet de séparer les données destinées à l'entraînement, à la validation et aux tests. Le dossier de téléchargement initial est conservé sans modification.

6. Statistiques, documentation et améliorations

La dernière étape a consisté à mettre en place un système de statistiques permettant de produire un rapport récapitulatif des opérations effectuées. Ce rapport contient notamment la date d'exécution, les paramètres utilisés, les effectifs obtenus, la répartition des fichiers, le nombre de doublons détectés ainsi que les éventuelles erreurs rencontrées. Nous avons également intégré l'option --all, qui permet d'exécuter automatiquement les six fonctions principales du programme dans l'ordre prévu. Une condition d'arrêt a été prévue avec le code de sortie 3 lorsqu'aucun lien multimédia n'est extrait. Par ailleurs, nous avons rédigé un fichier README.md pour présenter le fonctionnement du projet et complété le fichier tests.md avec les différents tests demandés. Enfin, deux améliorations supplémentaires ont été apportées : la génération d'un index au format JSON, vérifié avec l'outil jq, et l'utilisation de couleurs dans le terminal pour faciliter la lecture des résultats. Les messages de réussite [OK] apparaissent en vert, tandis que les messages d'erreur ou de refus sont affichés en rouge.

Conclusion

La réalisation de ce projet nous a permis de mettre en pratique plusieurs notions importantes en informatique, notamment la programmation Shell, l'automatisation des tâches, la manipulation des fichiers, le traitement des données et l'utilisation des commandes Linux. Nous avons également compris l'importance de la vérification des fichiers, de la détection des doublons et de l'organisation des données dans la constitution d'un dataset fiable. En définitive, ce projet nous a permis de développer une solution automatisée structurée et documentée, tout en renforçant nos compétences en programmation et en gestion de données multimédias.